
2. SUPERVISED LEARNING

CURSO

Data Science Machine Learning & Deep Learning con Python


Naive Bayes

Naive Bayes


- Teorema de Bayes

$$P(Y/X) = \frac{P(X/Y) * P(Y)}{P(X)}$$

Información conocida



Información inferida



$$P(\text{Clase} | \text{Datos}) = \frac{P(\text{Datos}|\text{Clase}) * P(\text{Clase})}{P(\text{Datos})}$$

Naive Bayes

- Se basa en el teorema de Bayes.
- Supuesto “Naive”: Independencia entre las características, dada una clase.

$$P(y \mid x_1, \dots, x_n) = \frac{P(y)P(x_1, \dots, x_n \mid y)}{P(x_1, \dots, x_n)}$$

Naive Bayes

- Dado el supuesto:

$$P(x_i | y, x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n) = P(x_i | y),$$

$$P(y | x_1, \dots, x_n) = \frac{P(y) \prod_{i=1}^n P(x_i | y)}{P(x_1, \dots, x_n)}$$

Naive Bayes

- La condición de optimización es:

$$P(y \mid x_1, \dots, x_n) \propto P(y) \prod_{i=1}^n P(x_i \mid y)$$

↓

$$\hat{y} = \arg \max_y P(y) \prod_{i=1}^n P(x_i \mid y),$$

Support Vector Machine

- Maximizar la distancia entre las categorías y la recta que las separa.




SVM

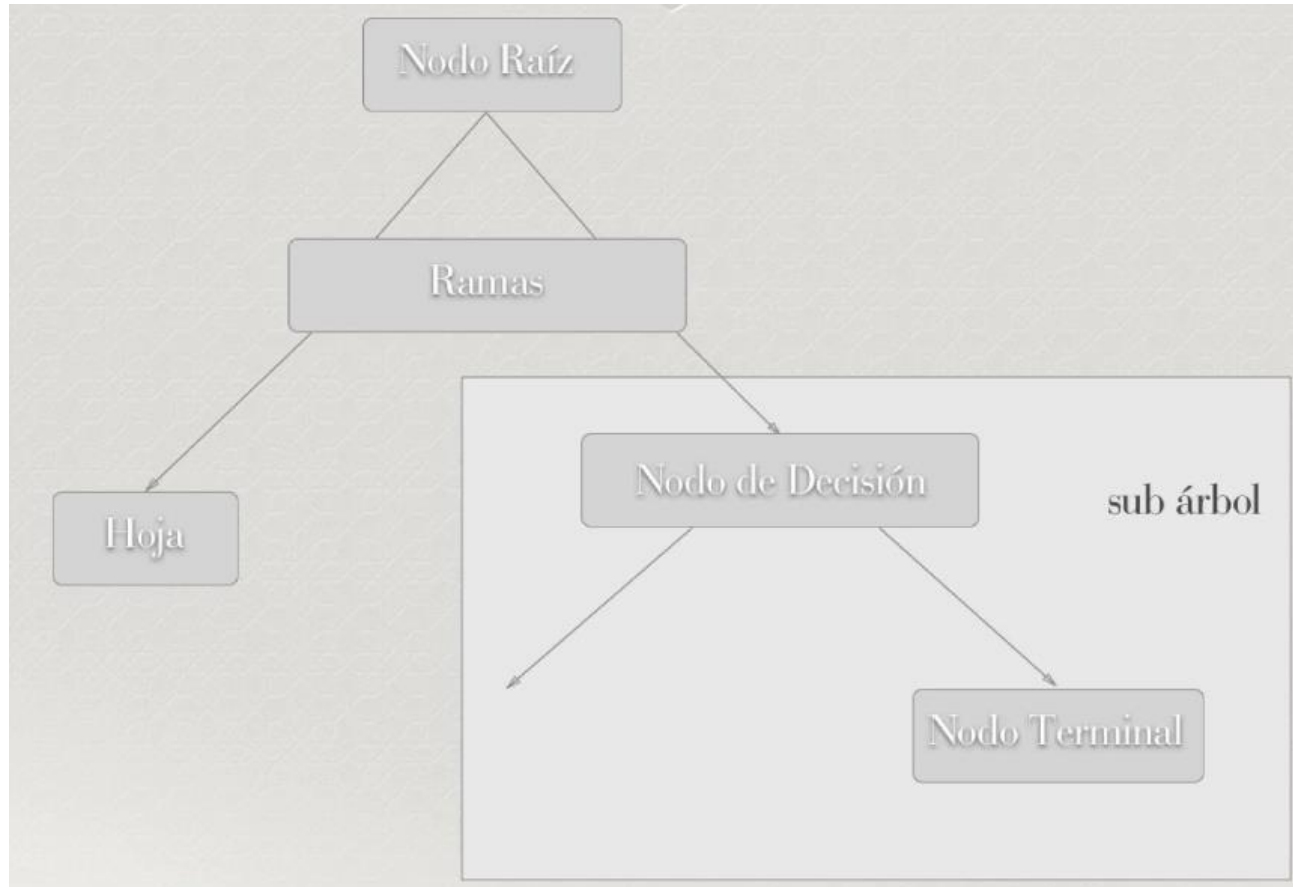
- Su función objetivo considera dos tipos de errores: Clasificación y margen.



Árboles de Decisión

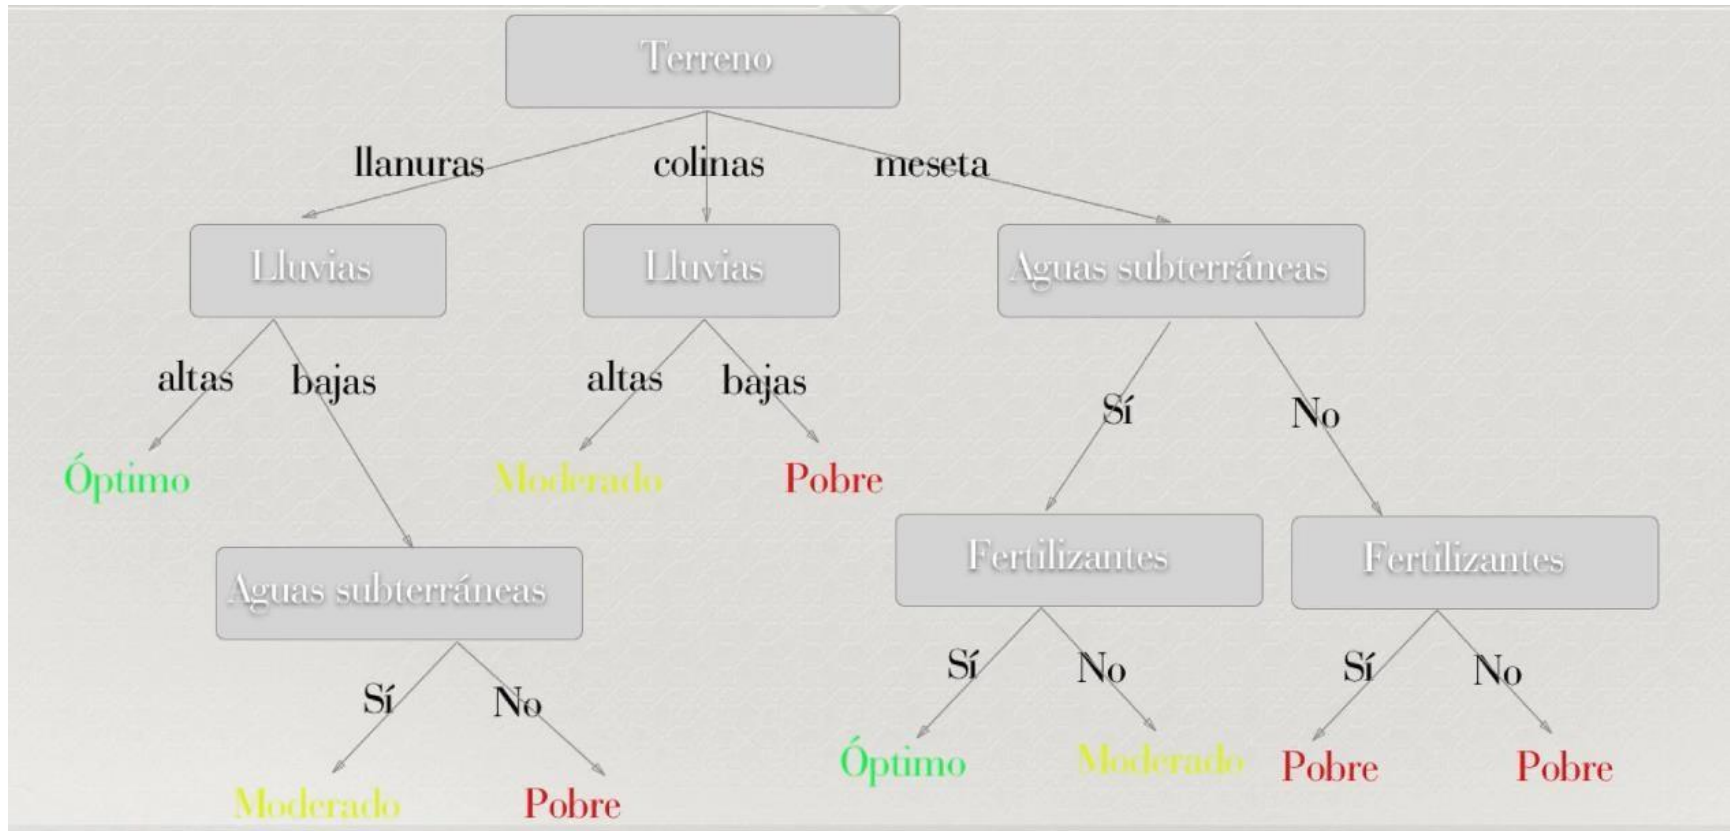


Componentes de un árbol




Lugar	Lluvias	Terreno	Fertilizantes	Aguas Subterráneas	Cosecha
P ₁	Altas	Llanura	Si	Si	Óptima
P ₂	Bajas	Colinas	No	Si	Pobre
P ₃	Bajas	Meseta	No	Si	Moderada
P ₄	Altas	Meseta	No	Si	Moderada
P ₅	Altas	Llanura	Si	No	Óptima
P ₆	Bajas	Colinas	No	No	Pobre
P ₇	Bajas	Meseta	No	No	Pobre
P ₈	Medias	Meseta	No	No	Pobre
P ₉	Altas	Colinas	Si	Si	Moderada
P ₁₀	Medias	Meseta	Si	Si	Óptima
P ₁₁	Altas	Meseta	Si	No	Óptima
P ₁₂	Medias	Meseta	Si	No	Moderada
P ₁₃	Altas	Colinas	Si	No	Moderada
P ₁₄	Bajas	Llanura	Si	Si	Moderada
P ₁₅	Medias	Llanura	Si	No	Moderada
P ₁₆	Bajas	Llanura	No	No	Pobre
P ₁₇	Bajas	Colinas	Si	No	Pobre
P ₁₈	Medias	Meseta	No	No	Pobre
P ₁₉	Altas	Llanura	No	Si	Moderada
P ₂₀	Medias	Colinas	Si	Si	Moderada

Decisiones de un árbol



Árboles de Decisión

- Entropía




- Entropía: Controla la partición de los datos.
- Information Gain: Cantidad de información ganada por una variable debido a la observación de otra variable.

En las versiones más básicas, los árboles solo utilizaban variables explicativas categóricas.


Entropía

$$H(S) = \sum_{i=1}^n -p_i \log_2(p_i)$$


n categorías para una variable objetivo a predecir del dataset



Cálculo de la entropía



- Information Gain



Cálculo de gain

$$\Delta H(S, V) = H(S) - \sum_{c \in V} \frac{|V = c|}{|V|} H(V = c)$$

$Terreno = \{llanura, meseta, colina\}$


Terreno	Óptima	Moderada	Pobre
Colinas	0	3 (50%)	3 (50%)
Llanuras	2 (33%)	1 (17%)	3 (50%)
Mesetas	2 (25%)	3 (37.5%)	3 (37.5%)

$$H(T = c) = - \left(\frac{0}{6} \log_2 \left(\frac{0}{6} \right) + \frac{3}{6} \log_2 \left(\frac{3}{6} \right) + \frac{3}{6} \log_2 \left(\frac{3}{6} \right) \right) = 1$$

$$H(T = ll) = - \left(\frac{2}{6} \log_2 \left(\frac{2}{6} \right) + \frac{1}{6} \log_2 \left(\frac{1}{6} \right) + \frac{3}{6} \log_2 \left(\frac{3}{6} \right) \right) = 1.45$$

$$H(T = m) = - \left(\frac{2}{8} \log_2 \left(\frac{2}{8} \right) + \frac{3}{8} \log_2 \left(\frac{3}{8} \right) + \frac{3}{8} \log_2 \left(\frac{3}{8} \right) \right) = 1.56$$

Cálculo de gain

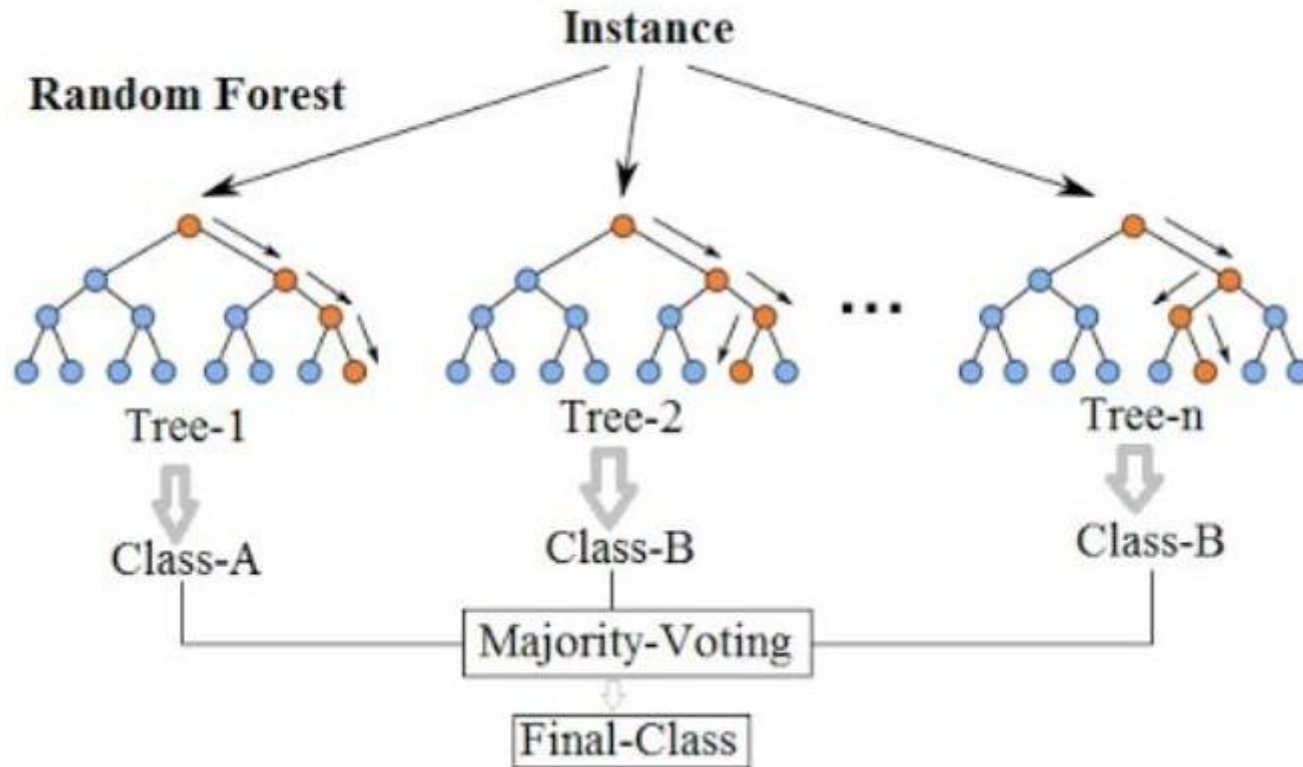


$$\Delta H(S, T) = 1.5 - \left(\frac{6}{20} \cdot H(T = ll) + \frac{6}{20} \cdot H(T = c) + \frac{8}{20} \cdot H(T = m) \right) = 0.14$$

Random Forest

- Genera diversos árboles de decisión con submuestras, la regla de decisión final toma el promedio de los árboles generados.
- Usualmente el tamaño de las submuestras es el mismo que el de la muestra total.
- La ganancia de Random Forest, con respecto a los árboles de decisión tradicionales, es mayor precisión y evita el overfitting.

Random Forest Simplified



XGBoost

- El criterio de optimización considera dos componentes: Training Loss y Regularization.

$$\text{obj}(\theta) = L(\theta) + \Omega(\theta)$$

$$L(\theta) = \sum_i (y_i - \hat{y}_i)^2$$

$$L(\theta) = \sum_i [y_i \ln(1 + e^{-\hat{y}_i}) + (1 - y_i) \ln(1 + e^{\hat{y}_i})]$$

$L(\theta)$ = Función que se desea optimizar

La predicción es la suma de la predicción de varios árboles.

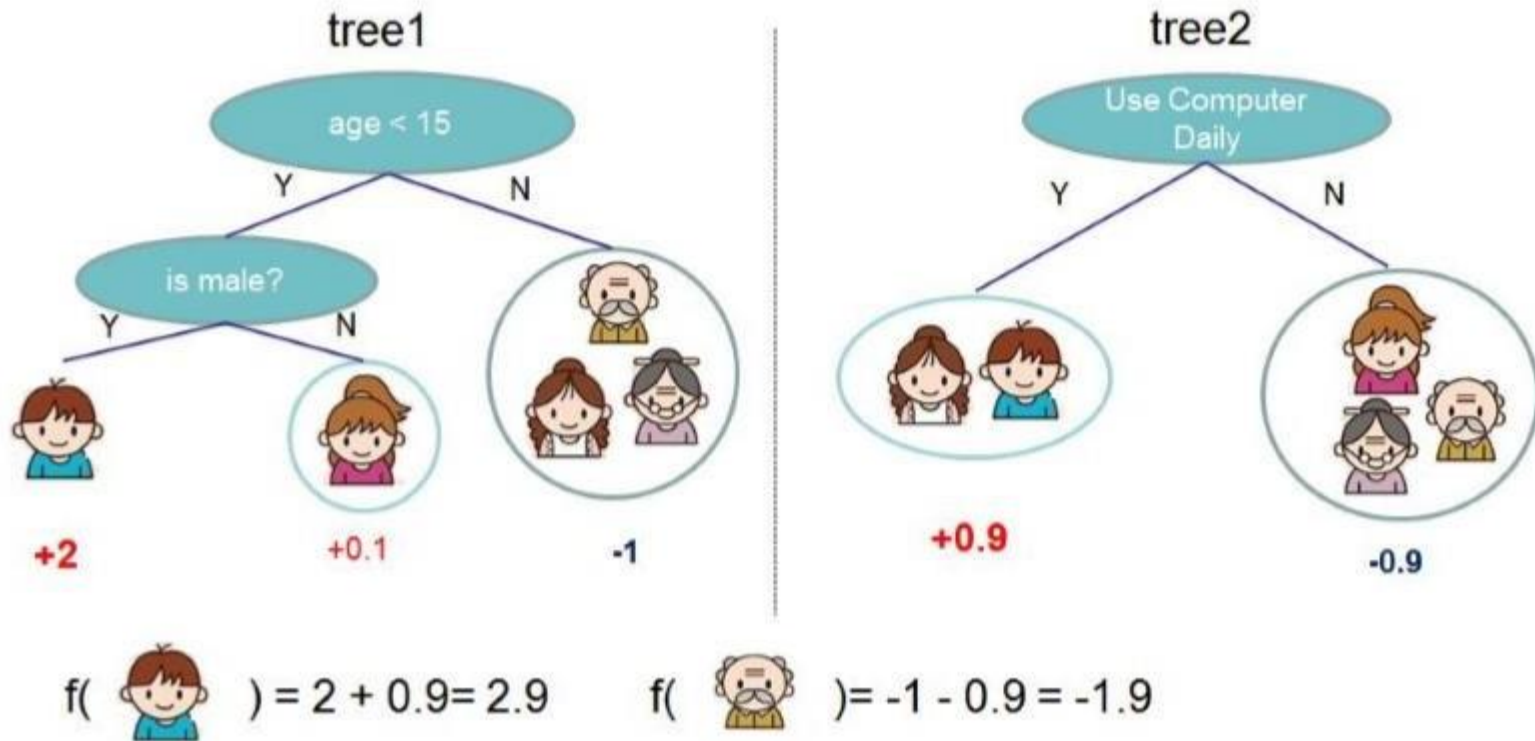
- Complejidad:

$$\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

T: cantidad de hojas del árbol

w_j : valor de la j-ésima hoja

Gamma y Lambda son hiper-parámetros



Las predicciones son la suma de scores por cada árbol



www.diplomadosperu.com.pe